

UNIVERSIDAD DEL VALLE DE GUATEMALA

Security Data Science

Sección 10

Jorge Yass



## Proyecto Final

Mark Albrand, 21004

Guatemala, 31 de mayo de 2025

## Resumen

Este trabajo aborda el problema de la alta tasa de falsos positivos en la detección de fraudes financieros. Se propone mejorar la efectividad del modelo mediante la implementación de funciones de evaluación personalizadas en LightGBM, enfocadas específicamente en regiones con alta incidencia histórica de fraudes. El objetivo principal es reducir los falsos positivos sin comprometer la capacidad de detección, optimizando la función '*Detectar fraudes en regiones con alta incidencia histórica*'. Se diseñaron y compararon tres funciones personalizadas, y se demostró una mejora significativa respecto al modelo base.

## Metodología

### Preprocesamiento de datos

El conjunto de datos original fue enriquecido mediante la creación de nuevas variables que capturan información histórica y regional sobre las transacciones. Esto permitió incorporar conocimiento contextual útil para la detección de fraudes.

Se dividen en tres tipos de variables:

#### A. Regionales

- a. `fraud_rate_by_zip`: Proporción de fraudes por código postal.
- b. `fraud_rate_by_city`: Proporción de fraudes por ciudad.
- c. `fraud_rate_by_state`: Proporción de fraudes por estado.
- d. `city_fraud_count`: Número total de fraudes históricos por ciudad.

#### B. Temporales y regionales

- a. `monthly_zip_fraud_rate`: Proporción de fraudes por código postal y mes.
- b. `rolling_fraud_rate_by_zip`: Tasa de fraude acumulada por código postal usando una ventana móvil de los últimos 100 registros.

#### C. Geolocalización

- a. `region_density`: Densidad de transacciones en regiones geográficas, calculada a partir de la frecuencia de transacciones en celdas geográficas (bins de latitud y longitud).

#### D. Clasificación

- a. `high_risk_region`: Variable binaria que indica si una transacción ocurrió en una región con una tasa de fraude superior al percentil 90 de `fraud_rate_by_zip`.

## Separación de datos

En un inicio, se separó la información de manera aleatoria, con 75% de ella para entrenamiento y 25% para validación. Luego de tener una revisión con el equipo de PlusTI, se sugirió que esta separación se hiciera de manera temporal.


Por lo que se decidió seguir este consejo. Usando percentiles se obtiene la misma cantidad de datos que el método anterior, pero ahora ambos conjuntos mantienen un conjunto lineal de datos.

## Implementación

### Modelo base

Este modelo, como su nombre lo indica, es la base sobre la cuál se constuirá nuestro modelo personalizado. No utiliza ninguna de las variables creadas en la fase de ingeniería de características.

Para este modelo, las columnas más importantes fueron:




*Imagen 1. Columnas más importantes para el modelo base*

### Modelo personalizado

Para el modelo personalizado, además de utilizar las nuevas variables, se desarrollaron las siguientes funciones de optimización:

1. fp\_penalty\_metric: penaliza falsos positivos en relación a verdaderos positivos.
2. custom\_f1: versión ajustada de la métrica F1 con mayor estabilidad numérica.
3. recall\_high\_risk\_eval: maximiza el recall de fraudes en zonas de alto riesgo.



*Imagen 2. Columnas más importantes para el modelo base*

Como se puede ver, con el modelo personalizado, dentro de las columnas más importantes se encuentran la mayoría de las nuevas variables realizadas para el análisis de la función a optimizar.

## Resultados

A continuación, se adjuntan los resultados obtenidos:

Métrica	Modelo Base	Modelo Personalizado
AUC-ROC	0.9975	0.9994
F1-Score	0.411	0.938
Precisión (1)	0.262	0.895
Precisión (0)	0.9998	0.9999
Recall (1)	0.9568	0.986
Recall (0)	0.9897	0.9996
Accuracy	98.96%	99.95%

*Tabla 1. Resultados en métricas de evaluación*

Se puede observar una mejora considerable en el modelo implementado, sobre todo en las métricas de F1 y de precisión. Esto demuestra que las variables y métricas creadas ayudaron a optimizar la función objetivo.

## Conclusiones

- Las funciones de evaluación personalizadas son herramientas efectivas para adaptar modelos de clasificación a objetivos de negocio específicos.
- En el caso particular de zonas de alto riesgo, priorizar el recall fue clave para mejorar la utilidad del modelo.
- La estrategia de ingeniería de características, combinada con métricas diseñadas a medida, permitió superar ampliamente el rendimiento del modelo base.
- Se recomienda la adopción de estas prácticas en escenarios de riesgo asimétrico, como la detección de fraudes, donde las decisiones tienen costos muy diferentes.

## Anexos

Link a github: [markalbrand56/SDS-Proyecto-1](https://github.com/markalbrand56/SDS-Proyecto-1)